# Emulació de la distorsió de guitarra elèctrica amb xarxes neuronals

**Valentí Ubach Martínez**

Data Science

Màster universitari en Ciència de Dades

Nom del director/a del TF:
**Ismael Benito Altamirano**

Nom del de/la PRA:
David Masip Rodó

Novembre de 2026

Universitat Oberta de Catalunya



Aquesta obra està subjecta a una llicència de Reconeixement-NoComercial-CompartirIgual
https://creativecommons.org/licenses/by-nc/3.0/es/

# Fitxa del Treball Final

| | |
|---|---|
| **Títol del treball:** | Emulació de la distorsió de guitarra elèctrica amb xarxes neuronals |
| **Nom de l'autor/a:** | Valentí Ubach Martínez |
| **Nom del director/a del TF:** | Ismael Benito Altamirano |
| **Nom del de/la PRA:** | David Masip Rodó |
| **Data de lliurament:** | Novembre de 2026 |
| **Titulació o programa:** | Màster universitari en Ciència de Dades |
| **Àrea del treball final:** | Data Science |
| **Idioma del treball:** | Català |
| **Paraules clau:** | emulació d'amplificadors de guitarra, xarxes neuronals, modelatge de caixa negra |

**Resum del treball**

La distorsió és un element central del so de la guitarra elèctrica. Tradicionalment s'obté amb amplificadors i pedals analògics, i reproduir-la digitalment requereix simular el circuit de cada equip. Aquest Treball Final de Màster aborda el problema des de la ciència de dades: tractar l'efecte com una *caixa negra* i aprendre'n el comportament amb xarxes neuronals a partir de parelles d'enregistraments de guitarra neta i distorsionada.

El treball crearà un conjunt de dades propi, entrenarà i compararà diversos models neuronals (LSTM i GRU de diferents mides) i els avaluarà amb mètriques objectives sobre dades no vistes. L'objectiu és determinar quin model reprodueix més fidelment la distorsió i quantes dades calen per entrenar-lo.

**Abstract**

Distortion is a defining element of the electric guitar sound. It is traditionally produced by analogue amplifiers and pedals, and reproducing it digitally requires simulating the circuit of each device. This Master's Thesis approaches the problem from a data science perspective: the effect is treated as a *black box* and its behaviour is learned with neural networks from paired recordings of clean and distorted guitar. The work will create its own dataset, train and compare several neural models (LSTM and GRU networks of different sizes) and evaluate them with objective metrics on unseen data. The goal is to determine which model reproduces the distortion most faithfully and how much data is needed to train it.

# Índex

**1 Introducció** **9**
1.1 Context i justificació del treball . . . 9
1.2 Motivació personal . . . 9
1.3 Objectius del treball . . . 10
1.3.1 Hipòtesi . . . 10
1.3.2 Objectius parcials . . . 10
1.3.3 Abast . . . 10
1.4 Impacte en sostenibilitat, ètic-social i de diversitat . . . 10
1.5 Enfocament i mètode seguit . . . 11
1.5.1 Estratègia de recerca . . . 11
1.5.2 Metodologia de treball . . . 11
1.6 Planificació del treball . . . 11
1.7 Breu sumari de productes obtinguts . . . 12
1.8 Breu descripció dels altres capítols de la memòria . . . 12
1.9 Declaració sobre l'ús d'intel·ligència artificial generativa . . . 12

**2 Estat de l'art** **13**
2.1 Metodologia de la revisió . . . 13
2.2 La distorsió de guitarra com a sistema no lineal amb memòria . . . 14
2.3 Modelatge d'àudio virtual analògic . . . 14
2.3.1 Modelatge de caixa blanca . . . 15
2.3.2 Modelatge de caixa grisa . . . 15
2.3.3 Modelatge de caixa negra . . . 16
2.4 Models neuronals per a l'emulació de la distorsió . . . 16
2.4.1 Models convolucionals . . . 16
2.4.2 Models recurrents . . . 16
2.4.3 Models híbrids i de caixa grisa neuronal . . . 18
2.4.4 Condicionament pels controls de l'equip . . . 18
2.4.5 Resum comparatiu . . . 18
2.5 Funcions de pèrdua i avaluació . . . 19
2.5.1 Funcions de pèrdua . . . 19
2.5.2 Mètriques objectives . . . 20
2.5.3 Avaluació perceptual . . . 20
2.6 Dades d'entrenament . . . 20
2.7 Execució en temps real . . . 21

2.8 Solucions existents . . . . . 21
2.9 Síntesi i posicionament del treball . . . . . 22

**3 Materials i mètodes 23**

**4 Resultats 24**

**5 Conclusions i treballs futurs 25**

**6 Glossari 26**

**7 Bibliografia 27**

**8 Annexos 31**

# Índex de figures

2.1 Taxonomia de les tècniques de modelatge virtual analògic. . . . . 15
2.2 Model recurrent amb connexió residual utilitzat habitualment per a l'emulació de distorsió [3]. . . . . 17

# Índex de taules

1.1 Planificació de les tasques del projecte. . . . . 12

2.1 Resum dels treballs més rellevants sobre emulació neuronal de distorsió i amplificadors. . . . . 19
2.2 Comparació de solucions existents de captura neuronal. . . . . 22

# Capítol 1

# Introducció

## 1.1 Context i justificació del treball

La distorsió és un dels trets que defineixen el so de la guitarra elèctrica. Es produeix quan el senyal de l'instrument passa per un sistema no lineal (una etapa de vàlvules saturada, un pedal de díodes o un preamplificador d'estat sòlid) que n'altera la forma d'ona, hi afegeix harmònics i comprimeix la dinàmica. Aquest comportament depèn de l'amplitud i també de la història recent del senyal, cosa que el converteix en un sistema dinàmic no lineal i difícil de modelar [1].

Tradicionalment, la distorsió s'ha reproduït digitalment simulant el circuit de cada equip, una tasca que requereix molt coneixement i feina d'enginyeria [1, 2]. Durant els darrers anys, les xarxes neuronals han permès una alternativa: aprendre el comportament de l'equip directament a partir de dades, és a dir, de parelles d'enregistraments de guitarra neta i distorsionada. Amb aquest enfocament *de caixa negra* s'han aconseguit emulacions que en proves d'escolta són difícils de distingir de l'original [3, 4], i avui és la tecnologia de diversos productes comercials i eines de codi obert [5].

Des del punt de vista de la ciència de dades, el problema és un cas complet d'aprenentatge supervisat sobre sèries temporals: inclou la captura de les dades, el seu preprocessament i l'entrenament, l'avaluació i la comparació de models. Té interès per a la recerca en processament d'àudio, per a la indústria de la tecnologia musical i per als músics, que poden accedir a sons d'equips cars o inaccessibles amb un ordinador i una interfície d'àudio.

Com a punt de partida, ja s'ha construït un prototip senzill: s'ha gravat guitarra a REAPER amb el senyal net i la sortida d'un plugin simulador d'amplificador i s'ha entrenat una xarxa LSTM amb PyTorch [6] que genera guitarra distorsionada a partir del senyal net. El prototip demostra que la idea és viable, però no s'ha avaluat amb rigor: l'error només s'ha mesurat sobre les dades d'entrenament i el model no s'ha comparat amb cap alternativa. El TFM vol fer aquest pas.

## 1.2 Motivació personal

La motivació d'aquest treball neix de la intersecció de dues aficions: la música i la programació aplicada a l'anàlisi de dades i la intel·ligència artificial. Com a estudiant del màster, m'atrau la possibilitat de fer servir xarxes neuronals per emular el funcionament d'un amplificador de

guitarra, un problema que conec bé com a músic. També m'atrau perquè em permet recórrer totes les fases d'un projecte de ciència de dades amb un resultat que es pot *escoltar*: generar les dades jo mateix, entrenar models i comprovar, escoltant-los, si funcionen.

## 1.3 Objectius del treball

### 1.3.1 Hipòtesi

*Una xarxa neuronal recurrent petita, entrenada amb pocs minuts d'àudio gravat a casa, pot reproduir amb fidelitat la distorsió d'un simulador d'amplificador sobre dades que no ha vist durant l'entrenament.*

### 1.3.2 Objectius parcials

**O1.** Crear un conjunt de dades de guitarra neta i distorsionada, ben alineat i dividit en entrenament, validació i test.

**O2.** Entrenar diversos models neuronals (com a mínim LSTM i GRU de diferents mides) amb un procés reproduïble.

**O3.** Avaluar-los amb mètriques objectives sobre dades no vistes i comparar-los.

Aquests objectius es concreten en les preguntes de recerca següents:

- **PR1.** Quina quantitat de dades cal perquè el model generalitzi?
- **PR2.** Quina arquitectura i mida de model reprodueixen millor la distorsió?

### 1.3.3 Abast

## 1.4 Impacte en sostenibilitat, ètic-social i de diversitat

Aquest apartat analitza el treball segons les tres dimensions de la competència de Compromís Ètic i Global (CCEG) de la UOC i la seva relació amb els Objectius de Desenvolupament Sostenible (ODS) [7].

**Sostenibilitat.** L'entrenament de models d'aprenentatge profund consumeix energia [8]. En aquest treball l'impacte és baix perquè els models i les dades són petits, i es reduirà prioritzant els models compactes i limitant el nombre d'experiments. A més, un amplificador virtual pot substituir part dels equips físics, cosa que contribueix a l'**ODS 12** (producció i consum responsables).

**Comportament ètic i responsabilitat social.** El principal risc ètic és la *propietat intel·lectual*: el modelatge de caixa negra pot reproduir el so d'equips comercials. Per això, els models s'utilitzaran amb finalitats acadèmiques i no es distribuiran models que imitin productes comercials. El codi es publicarà amb una llicència oberta, en línia amb l'**ODS 4** (educació de qualitat) i l'**ODS 9** (indústria, innovació i infraestructura).

**Protecció de dades.** Les dades són enregistraments d'àudio de l'instrument fets per l'estudiant i no contenen cap dada personal, de manera que no cal aplicar el Reglament General de Protecció de Dades [9] ni el model de Protocol Ètic de la UOC. Si més endavant es fes una prova d'escolta amb participants, s'emplenaria aquest protocol abans de fer-la.

## 1.5 Enfocament i mètode seguit

### 1.5.1 Estratègia de recerca

Seguint la classificació d'Oates [10], el treball combina dues estratègies de recerca:

- **Disseny i creació**, per construir els artefactes: el conjunt de dades i els models.
- **Experiment**, per respondre les preguntes de recerca comparant models entrenats en condicions controlades.

Les tècniques de generació de dades seran la **recerca basada en documents**, per a l'estat de l'art, i la generació de dades **quantitatives** a partir dels experiments. La mètrica principal serà l'ESR (*error-to-signal ratio*) [3]:

$$\mathrm{ESR} = \frac{\sum_n \left(y[n] - \hat{y}[n]\right)^2}{\sum_n y[n]^2}, \tag{1.1}$$

on $y$ és la sortida real de l'equip i $\hat{y}$ la predicció del model. També es mesurarà el temps de càlcul dels models.

Les eines previstes són REAPER per a la captura i Python, amb PyTorch [6], NumPy i Matplotlib, per a l'entrenament i l'anàlisi.

### 1.5.2 Metodologia de treball

Es van considerar tres estratègies: (1) utilitzar una eina existent com Neural Amp Modeler [5], que seria ràpid però amagaria les decisions de disseny; (2) reproduir un treball publicat amb les seves dades [4], que deixaria fora la captura de dades pròpies; i (3) evolucionar el prototip propi cap a un estudi sistemàtic. S'ha triat la tercera perquè cobreix tot el procés de ciència de dades, des de la captura fins a la presentació de resultats, i aprofita la feina feta.

El desenvolupament seguirà una metodologia **iterativa basada en prototips**: cada iteració (alineada amb les PEC) produeix un resultat avaluable que orienta la següent. Els recursos necessaris són un ordinador amb GPU, una interfície d'àudio, una guitarra elèctrica i el programari indicat, tot ja disponible.

## 1.6 Planificació del treball

La taula 1.1 recull les tasques previstes, les seves dates i dependències. Les dates s'han d'ajustar al calendari oficial del semestre.

Taula 1.1: Planificació de les tasques del projecte.

| Id | Tasca | Inici | Fi | Depèn de |
|---|---|---|---|---|
| *PEC1 – Proposta* | | | | |
| T1 | Definició del treball i redacció de la proposta | 19/10/2026 | 08/11/2026 | – |
| *PEC2 – Estat de l'art* | | | | |
| T2 | Cerca i lectura de bibliografia | 09/11/2026 | 22/11/2026 | T1 |
| T3 | Redacció de l'estat de l'art | 16/11/2026 | 29/11/2026 | T2 |
| *PEC3 – Implementació* | | | | |
| T4 | Captura i preparació del conjunt de dades | 30/11/2026 | 13/12/2026 | T3 |
| T5 | Entrenament i comparació de models | 07/12/2026 | 03/01/2027 | T4 |
| *PEC4 – Memòria* | | | | |
| T6 | Redacció de la memòria final | 04/01/2027 | 24/01/2027 | T5 |
| *PEC5 – Defensa* | | | | |
| T7 | Presentació i defensa | 25/01/2027 | 07/02/2027 | T6 |

## 1.7 Breu sumari de productes obtinguts

## 1.8 Breu descripció dels altres capítols de la memòria

## 1.9 Declaració sobre l'ús d'intel·ligència artificial generativa

[Revisa aquest apartat perquè reflecteixi exactament l'ús que n'has fet i comenta'l amb el tutor/a.] S'ha utilitzat l'assistent Claude (Anthropic) per analitzar el prototip, cercar bibliografia i redactar un primer esborrany de la proposta i de l'estat de l'art. L'estudiant ha revisat i validat tots els continguts i les referències, i n'assumeix la responsabilitat.

# Capítol 2

# Estat de l'art

Aquest capítol revisa com s'ha abordat fins ara l'emulació digital de la distorsió de guitarra, amb èmfasi en els mètodes basats en dades. Comença descrivint com s'ha fet la revisió (secció 2.1) i les característiques del sistema que es vol modelar (secció 2.2). A continuació presenta les famílies clàssiques de modelatge (secció 2.3) i, amb més detall, els models neuronals (secció 2.4), les funcions de pèrdua i mètriques d'avaluació (secció 2.5), les dades d'entrenament (secció 2.6), l'execució en temps real (secció 2.7) i les solucions disponibles al mercat (secció 2.8). Acaba amb una síntesi dels buits detectats i de com s'hi posiciona aquest TFM (secció 2.9).

## 2.1 Metodologia de la revisió

D'acord amb Oates [10], l'estat de l'art s'ha elaborat amb una estratègia d'enquesta bibliogràfica (*survey*) que fa servir la recerca basada en documents com a tècnica de generació de dades. La cerca s'ha fet en tres passos:

1. **Punt de partida.** Dues revisions de referència [1, 2] han servit per identificar els autors, grups i congressos principals de l'àmbit.
2. **Cerca sistemàtica.** S'ha cercat a Google Scholar, Web of Science, IEEE Xplore, arXiv i l'arxiu de la conferència DAFx (*Digital Audio Effects*) amb combinacions de les paraules clau *guitar amplifier modelling*, *distortion*, *virtual analog*, *black-box*, *neural network*, *LSTM*, *WaveNet*, *real-time* i *audio effects*.
3. **Bola de neu.** S'han seguit les referències i les citacions dels treballs més rellevants, especialment els del grup d'acústica de la Universitat Aalto i del Centre for Digital Music de la Queen Mary University of London.

S'han prioritzat els articles revisats per parells en revistes i congressos dels darrers deu anys, sense excloure treballs fonamentals anteriors. Les preimpressions (arXiv), el programari i les pàgines web de fabricants s'han utilitzat només per descriure eines i productes, o resultats molt recents encara no publicats en una revista.

## 2.2 La distorsió de guitarra com a sistema no lineal amb memòria

La cadena de so d'una guitarra elèctrica distorsionada sol estar formada per un o més pedals d'efectes, el preamplificador, l'etapa de potència, el transformador de sortida i la caixa d'altaveus [1]. La distorsió apareix quan algun d'aquests elements treballa fora de la seva zona lineal: els díodes d'un pedal de *overdrive* que retallen el senyal, les vàlvules d'un preamplificador amb guany alt, o la saturació de l'etapa de potència. Des del punt de vista del processament de senyal, aquest sistema té tres propietats que en dificulten el modelatge [1, 11]:

- **No linealitat.** La sortida no és proporcional a l'entrada: apareixen harmònics i productes d'intermodulació, i el resultat depèn molt del nivell del senyal.
- **Memòria.** Els condensadors i els filtres del circuit (per exemple, la xarxa de to) fan que la sortida depengui de l'entrada passada. Alguns fenòmens, com la caiguda de tensió de l'alimentació (*sag*), tenen constants de temps de desenes de mil·lisegons.
- **Generació d'aliàsing.** Com que la no linealitat crea harmònics per sobre de la freqüència de Nyquist, una implementació digital ingènua els replega dins la banda audible. Per evitar-ho es fa servir el sobremostreig, que encareix el càlcul.

Aquestes propietats expliquen per què un model sense memòria (una simple funció de transferència estàtica) no és suficient, i per què el sistema s'ha de tractar com un sistema dinàmic no lineal.

Segons on i com es produeix la saturació, se solen distingir diversos tipus de distorsió [1, 11]:

- ***Overdrive***: retall suau (*soft clipping*), típicament amb díodes al llaç de realimentació d'un amplificador operacional. El senyal se satura de manera gradual i conserva part de la dinàmica de la interpretació.
- **Distorsió**: retall dur (*hard clipping*), típicament amb díodes connectats a massa. El resultat és més comprimit i ric en harmònics.
- ***Fuzz***: saturació extrema de transistors, amb efectes de polarització que depenen del nivell recent del senyal i que, per tant, tenen memòria llarga.
- **Distorsió d'amplificador**: saturació de les etapes de vàlvules del preamplificador i de l'etapa de potència, combinada amb la resposta en freqüència de la xarxa de to i del transformador.

Com a il·lustració, el retall suau i el retall dur es poden aproximar sense memòria amb funcions com $y = \tanh(g\,x)$ i $y = \max(-1, \min(1, g\,x))$, on $g$ és el guany. Els equips reals, però, envolten aquestes no linealitats de filtres i d'elements amb estat, i això és el que els models basats en dades han d'aprendre.

## 2.3 Modelatge d'àudio virtual analògic

L'emulació digital d'equips analògics d'àudio s'anomena *modelatge virtual analògic*. Les tècniques se solen classificar segons quant coneixement del circuit utilitzen [1, 2]. La figura 2.1 en resumeix la taxonomia, que s'utilitza per organitzar la resta del capítol.

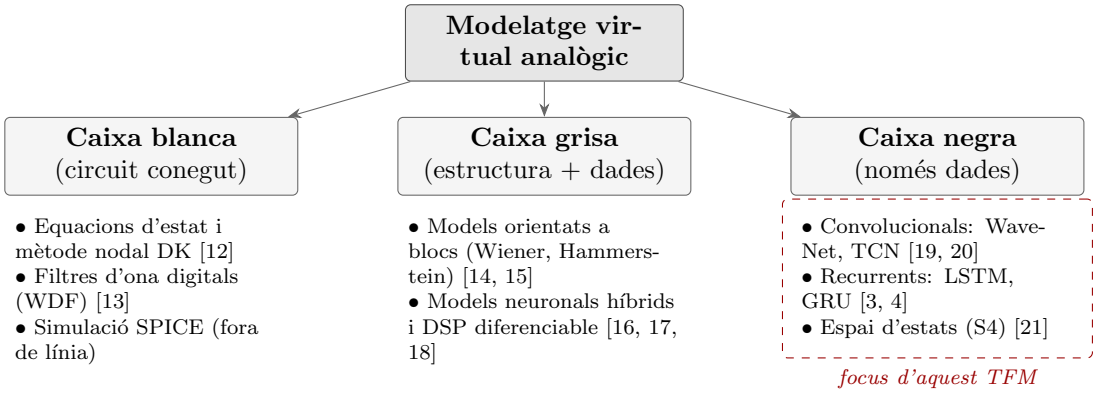



Figura 2.1: Taxonomia de les tècniques de modelatge virtual analògic.

### 2.3.1 Modelatge de caixa blanca

Els models de caixa blanca parteixen de l'esquema del circuit i dels models físics de cada component (resistències, condensadors, díodes, transistors i vàlvules). A partir d'aquí, plantegen el sistema d'equacions diferencials i el resolen numèricament. Dues famílies destaquen en l'àmbit de l'àudio. La primera és la formulació en espai d'estats generada automàticament a partir de l'anàlisi nodal, l'anomenat mètode DK, que Yeh *et al.* van aplicar a pedals i amplificadors de vàlvules [11, 12]. La segona són els filtres d'ona digitals (*Wave Digital Filters*, WDF), que conserven l'estructura modular del circuit i que s'han estès a topologies arbitràries [13].

L'avantatge principal d'aquests models és la fidelitat i la interpretabilitat: cada paràmetre correspon a un component real i els controls de l'equip es reprodueixen de manera natural. Els inconvenients són que cal conèixer l'esquema i els valors dels components, que el modelatge de les vàlvules és complex i que el cost computacional creix ràpidament amb el nombre d'elements no lineals [1]. Per això, en la pràctica és difícil escalar-los a molts equips diferents.

### 2.3.2 Modelatge de caixa grisa

Els models de caixa grisa combinen una estructura simplificada inspirada en el circuit amb paràmetres que s'ajusten a partir de mesures. Els més habituals són els *models orientats a blocs*, que encadenen filtres lineals i funcions no lineals estàtiques: un filtre seguit d'una no linealitat (model de Wiener), una no linealitat seguida d'un filtre (model de Hammerstein) o la combinació de tots dos. Eichas *et al.* van aplicar aquesta estructura a amplificadors de guitarra, ajustant-ne els paràmetres amb optimització iterativa a partir de mesures de l'equip real [14]. Per identificar aquests models s'han proposat senyals de mesura específics, com el sinus escombrat exponencial, que permet separar les contribucions de cada harmònic [15].

Aquests models són compactes i eficients, però la seva capacitat expressiva està limitada per l'estructura triada: els comportaments que no encaixen en la cascada de blocs (per exemple, dependències de l'estat com el *sag*) són difícils de capturar.

### 2.3.3 Modelatge de caixa negra

Els models de caixa negra aprenen la relació entre l'entrada i la sortida del sistema sense fer servir cap informació sobre el circuit. Durant molt de temps, els mètodes clàssics d'aquest tipus requerien massa paràmetres per representar distorsions fortes [1, 22]. Les xarxes neuronals han superat aquesta limitació: són aproximadors universals amb un cost que es pot controlar fixant la mida del model, i s'entrenen amb mètodes d'optimització estàndard. La secció següent n'analitza les variants.

## 2.4 Models neuronals per a l'emulació de la distorsió

En pocs anys, l'emulació neuronal ha passat de ser una línia de recerca a ser la tecnologia de nombrosos productes comercials [2]. El plantejament comú és un problema d'aprenentatge supervisat: donades les seqüències d'entrada $x[n]$ (senyal net) i de sortida $y[n]$ (senyal processat per l'equip), s'entrena una xarxa $f_\theta$ perquè $\hat{y}[n] = f_\theta(x[n], x[n-1], \dots)$ minimitzi una funció de pèrdua. Les arquitectures es diferencien sobretot en com representen la memòria del sistema.

### 2.4.1 Models convolucionals

Els primers resultats d'alta qualitat es van obtenir amb xarxes convolucionals inspirades en WaveNet [23], que encadenen convolucions dilatades i causals per obtenir un camp receptiu llarg amb pocs paràmetres. Amb $L$ capes de nucli $k$ i dilatacions $d_i$, el camp receptiu és

$$R = 1 + (k-1)\sum_{i=1}^{L} d_i, \tag{2.1}$$

de manera que, per exemple, deu capes amb $k = 3$ i dilatacions $1, 2, 4, \dots, 512$ cobreixen 2 047 mostres, uns 46 ms a 44,1 kHz. La memòria del model està limitada per aquest valor. Damskägg *et al.* van adaptar aquesta arquitectura per emular un preamplificador de vàlvules, eliminant la part generativa i fent que la xarxa predigui directament la mostra de sortida, i en va avaluar la qualitat amb proves d'escolta [19]. Poc després, el mateix grup va mostrar que el model podia emular pedals de distorsió en temps real [24].

En paral·lel, Martínez Ramírez i Reiss van proposar models d'extrem a extrem basats en convolucions i capes denses per a efectes no lineals [25]. També van comparar diverses arquitectures sobre efectes de tipus divers, incloent-hi distorsions i compressors [26]. Més endavant, les xarxes convolucionals temporals (TCN) es van optimitzar per al temps real, amb models molt petits que funcionen en CPU [20]. Comunità *et al.* van observar que ampliar el camp receptiu d'aquestes xarxes no és suficient per a efectes amb memòria llarga, com els *fuzz* i els compressors. Ho van resoldre amb una modulació de les característiques variable en el temps (TFiLM), que en el cas del *fuzz* redueix l'error aproximadament a la meitat [27].

### 2.4.2 Models recurrents

Les xarxes recurrents mantenen un estat intern $h[n]$ que resumeix la història del senyal, de manera que la memòria no depèn de la mida d'un camp receptiu. En la forma més habitual

per a l'emulació d'àudio, el model processa una mostra cada vegada:

$$h[n] = \mathrm{RNN}\big(x[n],\, h[n-1]\big), \qquad \hat{y}[n] = \mathbf{w}^{\top} h[n] + b + x[n], \tag{2.2}$$

on l'últim terme és una connexió residual que fa que la xarxa només hagi d'aprendre la diferència entre l'entrada i la sortida (figura 2.2). La cel·la LSTM [28] controla el flux d'informació amb tres portes (d'entrada, d'oblit i de sortida) i un estat de cel·la addicional. La GRU [29] en fa servir dues (d'actualització i de reinici) i és més lleugera. Amb una entrada escalar i $H$ unitats, i comptant els dos vectors de biaix que utilitza PyTorch, una capa LSTM té $4H^2+12H$ paràmetres i una GRU $3H^2+9H$. Com que el cost per mostra és aproximadament proporcional a aquest nombre, passar de 64 a 32 unitats redueix el càlcul aproximadament a una quarta part. Per exemple, dues capes LSTM de 64 unitats sumen uns 50 000 paràmetres, mentre que una sola LSTM de 40 unitats en té uns 6 900.

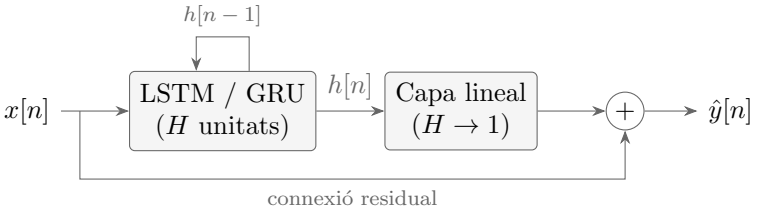



Figura 2.2: Model recurrent amb connexió residual utilitzat habitualment per a l'emulació de distorsió [3].

Schmitz i Embrechts van ser dels primers a utilitzar una LSTM [28] per emular un amplificador de vàlvules en temps real, amb un error inferior a l'1 % i amb el guany de l'amplificador com a paràmetre addicional [22].

El treball de referència és el de Wright *et al.* [3, 4]. Les seves aportacions principals són:

- Una arquitectura molt simple: una sola capa recurrent (LSTM o GRU [29]) seguida d'una capa lineal, amb una connexió residual que suma l'entrada a la sortida.
- Un procediment d'entrenament amb retropropagació truncada en el temps i un període d'escalfament inicial de l'estat ocult, en què no es calcula la pèrdua.
- L'ús de la pèrdua ESR amb un filtre de pre-èmfasi (secció 2.5).

En comparar-les amb WaveNet sobre pedals i amplificadors, les xarxes recurrents van obtenir una precisió similar amb un cost computacional menor [3]. A més, en les proves d'escolta MUSHRA els millors models van obtenir puntuacions properes a les de la referència oculta [4].

Estudis posteriors han confirmat la validesa de l'enfocament. Cassidy i De Sena van avaluar models LSTM i WaveNet d'un amplificador d'alt guany (Peavey 6505) amb cinc proves d'escolta. Entrenant amb material d'un gènere musical concret, el model LSTM va resultar indistingible de l'amplificador real en proves ABX [30]. Simionato i Fasciani van comparar sistemàticament diverses xarxes basades en estat i van concloure que l'LSTM és la millor opció per a la distorsió i l'equalització, tot i que amb diferències petites [31].

Aquesta conclusió, però, no és unànime. En un estudi amb una gran varietat d'efectes no lineals, Comunità *et al.* van trobar que els models d'espai d'estats estructurats (S4) amb condicionament variable en el temps obtenien els millors resultats, i que les LSTM eren les menys fiables [21]. La diferència entre aquests estudis es pot deure als efectes considerats

(els *fuzz* i compressors tenen més memòria que un *overdrive*), a la mida dels models i als procediments d'entrenament. Això indica que la tria d'arquitectura depèn de l'efecte concret i justifica una comparació experimental en cada cas.

### 2.4.3 Models híbrids i de caixa grisa neuronal

Una línia de recerca activa combina el coneixement del circuit amb l'aprenentatge automàtic per obtenir models més eficients, interpretables o que necessitin menys dades:

- Parker *et al.* van entrenar xarxes profundes que aprenen directament les equacions d'estat no lineals d'un circuit [16]. Wilczek *et al.* van fer servir equacions diferencials ordinàries neuronals per modelar circuits retalladors de díodes amb menys paràmetres i amb la possibilitat de canviar la freqüència de mostreig [32].
- Kuznetsov *et al.* van mostrar com entrenar filtres IIR amb retropropagació, cosa que permet integrar estructures clàssiques orientades a blocs dins d'un model diferenciable [33].
- Miklanek *et al.* van combinar xarxes recurrents amb l'anàlisi nodal del circuit i van obtenir models d'amplificador que necessiten moltes menys dades d'entrenament que un model de caixa negra [17].
- Yeh *et al.* van proposar un model de processament de senyal diferenciable (DDSP) amb mòduls per al preamplificador, la xarxa de to, l'etapa de potència i el transformador. Va obtenir resultats comparables als models neuronals de caixa negra amb menys del 10 % de les operacions per mostra [18].

Malgrat aquests avantatges, en la comparació àmplia de Comunità *et al.* els models de caixa grisa encara queden generalment per sota dels de caixa negra en precisió [21].

### 2.4.4 Condicionament pels controls de l'equip

Un model entrenat amb una configuració fixa (posició dels controls de guany, to, etc.) només reprodueix aquesta configuració, i per això s'anomena *captura* o *snapshot*. Per reproduir tot el rang de l'equip, el model es condiciona amb els valors dels controls. La manera més simple és concatenar-los a l'entrada de la xarxa [22, 4]. Alternatives més expressives són la modulació lineal de característiques (FiLM) [27] i les xarxes hiperparametritzades, en què una segona xarxa genera els pesos de la xarxa recurrent. Aquestes últimes superen la concatenació en un pedal d'*overdrive* i en un compressor [34]. A escala industrial, Juvela *et al.* (Neural DSP) van automatitzar la recollida de dades amb un robot que mou els controls de l'amplificador, i van obtenir un model LSTM condicionat que, en proves d'escolta, iguala una simulació de circuit SPICE d'alta qualitat i funciona en temps real [35].

### 2.4.5 Resum comparatiu

La taula 2.1 resumeix els treballs més rellevants per a aquest TFM.

Taula 2.1: Resum dels treballs més rellevants sobre emulació neuronal de distorsió i amplificadors.

| Ref. | Arquitectura | Sistema modelat | Aportació principal |
|---|---|---|---|
| [22] | LSTM | Amplificador de vàlvules | Error <1 % en temps real; guany com a entrada. |
| [19] | WaveNet | Preamplificador de vàlvules | Primer model convolucional d'alta qualitat per a amplificadors. |
| [3, 4] | LSTM, GRU, WaveNet | Pedals i amplificadors | Arquitectura recurrent mínima, pèrdua amb pre-èmfasi i proves MUSHRA; les RNN igualen WaveNet amb menys cost. |
| [36] | LSTM | Pedals i amplificadors | Filtres de pre-èmfasi a la pèrdua i millora perceptual. |
| [20] | TCN | Compressor analògic | TCN molt petites i eficients en CPU. |
| [27] | TCN + TFiLM | *Fuzz* i compressors | Modulació temporal per a efectes amb memòria llarga. |
| [30] | LSTM, WaveNet | Amplificador d'alt guany | Entrenament específic per gènere; LSTM indistingible en ABX. |
| [17] | RNN + anàlisi nodal | Amplificador | Caixa grisa neuronal amb poques dades. |
| [35] | LSTM condicionada | Amplificador (tots els controls) | Captura robotitzada; qualitat igual a SPICE en temps real. |
| [34] | HyperRNN | *Overdrive* i compressor | Condicionament amb hiperxarxes millor que la concatenació. |
| [18] | DDSP | Amplificador | Model interpretable amb <10 % de les operacions. |
| [31] | LSTM, GRU, S4, LRU | Diversos efectes | L'LSTM és la millor opció per a la distorsió. |
| [21] | LSTM, TCN, GCN, S4, caixa grisa | Diversos efectes no lineals | S4 amb condicionament temporal és la més precisa; LSTM la menys fiable. |

## 2.5 Funcions de pèrdua i avaluació

### 2.5.1 Funcions de pèrdua

La funció de pèrdua més utilitzada és l'**ESR** (*error-to-signal ratio*), l'energia de l'error normalitzada per l'energia del senyal objectiu (equació (1.1)) [3]. La normalització fa que l'error sigui comparable entre trossos amb volums molt diferents. Wright *et al.* hi afegeixen un terme que penalitza la diferència de component contínua (DC) [4].

L'ESR calculat directament sobre la forma d'ona dona el mateix pes a totes les freqüències, mentre que l'oïda és molt més sensible a les freqüències mitjanes i altes. Per això, Wright i Välimäki van proposar aplicar un **filtre de pre-èmfasi** a la sortida i a l'objectiu abans de calcular la pèrdua: un filtre passa-alts de primer ordre, de la forma $H(z) = 1 - \alpha z^{-1}$ amb $\alpha$ proper a 1, o una aproximació a la ponderació A. Les proves d'escolta van mostrar que els models entrenats així són percebuts com a més fidels [36].

Una alternativa és comparar els senyals en el domini freqüencial. La **pèrdua espectral de múltiples resolucions** (MR-STFT) calcula la diferència entre les magnituds de transformades de Fourier de temps curt amb diverses mides de finestra, de manera que captura alhora el detall temporal i el freqüencial [37]. Per a cada resolució $m$, amb $S_m$ la magnitud de l'espectrograma i $N_m$ el nombre d'elements, la pèrdua combina la convergència espectral i la diferència de magnituds logarítmiques:

$$\mathcal{L}_{\text{MR}} = \frac{1}{M}\sum_{m=1}^{M}\left(\frac{\|S_m(y) - S_m(\hat{y})\|_F}{\|S_m(y)\|_F} + \frac{1}{N_m}\left\|\log S_m(y) - \log S_m(\hat{y})\right\|_1\right). \tag{2.3}$$

Com que ignora la fase, aquesta pèrdua se sol combinar amb l'ESR, que sí que la té en compte. La biblioteca *auraloss* implementa aquestes pèrdues per a PyTorch [38]. Finalment, Wright *et*

*al.* han explorat l'entrenament adversari, que fins i tot permet aprendre a partir de dades no parellades [39].

### 2.5.2 Mètriques objectives

La pròpia ESR sobre un conjunt de test és la mètrica objectiva més reportada, i sovint es complementa amb l'error espectral. Altres mètriques d'origen perceptual, com PEAQ [40] o la distància d'àudio de Fréchet (FAD), que compara distribucions d'incrustacions extretes amb una xarxa preentrenada [41], s'utilitzen amb menys freqüència en aquest àmbit. Tanmateix, l'ESR no explica tota la qualitat percebuda: dos models amb un ESR semblant poden sonar diferent, especialment pel que fa als artefactes d'alta freqüència [36].

### 2.5.3 Avaluació perceptual

L'avaluació de referència són les proves d'escolta. El mètode **MUSHRA** (ITU-R BS.1534) demana als participants que puntuïn de 0 a 100 diversos estímuls respecte a una referència coneguda, incloent-hi una referència oculta i un estímul àncora de baixa qualitat [42]. És el mètode utilitzat per Wright *et al.* [4]. Les proves **ABX**, en què l'oient ha d'identificar quin de dos estímuls coincideix amb un tercer, permeten comprovar directament si un model és distingible de l'original [30]. Cassidy i De Sena també van observar que els fragments amb poc guany són els més exigents per distingir models [30], cosa que s'ha de tenir en compte a l'hora de triar el material d'avaluació.

## 2.6 Dades d'entrenament

Els models de caixa negra necessiten parelles de senyals sincronitzades: el senyal net a l'entrada de l'equip i la sortida corresponent. Normalment s'obtenen enviant un senyal de guitarra prèviament gravat (o un senyal de test) a l'equip, mitjançant una tècnica coneguda com a *reamping*, i gravant-ne la sortida. Els aspectes crítics que identifica la literatura són:

- **Representativitat.** El material ha de cobrir el rang de nivells, freqüències i tècniques que es faran servir. L'entrenament específic per a un gènere millora els resultats en aquest gènere [30].
- **Quantitat.** Els models de caixa negra solen entrenar-se amb uns quants minuts d'àudio per configuració. Els models de caixa grisa neuronal redueixen aquesta necessitat [17].
- **Alineació i nivells.** La latència de la interfície i dels processadors s'ha de compensar, i els nivells s'han de calibrar perquè la distorsió depèn de l'amplitud d'entrada.
- **Freqüència de mostreig.** Un model entrenat a una freqüència de mostreig no funciona correctament a una altra si no es fan adaptacions específiques [43].

Per facilitar la captura, les eines obertes i comercials proporcionen **senyals d'entrenament estandarditzats**, que combinen escombrats, soroll i fragments de guitarra. És el cas de Neural Amp Modeler [5] i del connector Proteus de GuitarML [44], que requereix un fitxer mono a 44,1 kHz. Pel que fa als conjunts de dades públics, EGFxSet conté 8 970 notes de guitarra processades amb dotze efectes reals, incloent-hi distorsions [45], i ToneTwist AFx recull efectes no lineals per a la comparació de models [21]. Una tendència recent és la generació de dades

sintètiques: Open-Amp utilitza centenars d'emulacions neuronals d'amplificadors creades per la comunitat per generar dades d'entrenament a gran escala i amb augmentació [46].

## 2.7 Execució en temps real

Per fer servir un model en directe, cada bloc d'àudio (típicament de 32 a 256 mostres) s'ha de processar abans que arribi el següent. Amb un bloc de $N$ mostres i una freqüència de mostreig $f_s$, el temps disponible és $T = N/f_s$: per exemple, 2,9 ms per a $N = 128$ a 44,1 kHz. La latència total d'entrada a sortida és com a mínim de dos blocs (un d'entrada i un de sortida) més la dels convertidors de la interfície, de manera que amb $N = 128$ supera els 5,8 ms. Per això és habitual caracteritzar un model amb el *factor de temps real*, el quocient entre el temps de càlcul i la durada de l'àudio processat, que ha de ser clarament inferior a 1 per deixar marge a la resta del sistema. Això imposa tres requisits: un temps de càlcul per mostra baix i estable, l'absència d'assignacions de memòria i de bloquejos al fil d'àudio, i una latència algorísmica nul·la o mínima [47]. Els models recurrents i les convolucions causals compleixen el tercer requisit perquè no necessiten mostres futures.

Les xarxes recurrents s'avaluen mostra a mostra, cosa que limita el paral·lelisme però les fa molt eficients per a mides petites. Les xarxes convolucionals poden aprofitar el processament per blocs i les instruccions vectorials [3, 20]. La biblioteca RTNeural implementa capes LSTM, GRU, convolucionals i denses amb mides definides en temps de compilació, sense assignacions dinàmiques i amb diversos motors de càlcul vectorial (Eigen, xsimd) [47]. És el motor que fa servir, per exemple, el connector Proteus [44].

Un problema específic és l'aliàsing. Les no linealitats apreses també generen harmònics per sobre de la freqüència de Nyquist. Carson *et al.* han proposat mètodes per executar xarxes recurrents a freqüències de mostreig diferents de la d'entrenament, cosa que permet el sobremostreig [43], i filtres de remostreig específics que redueixen l'aliàsing en models neuronals de distorsió [48].

## 2.8 Solucions existents

L'emulació basada en captures d'equips reals està plenament establerta al mercat, i diversos fabricants i projectes oberts fan servir xarxes neuronals. Alguns exemples representatius són:

- **Neural DSP Quad Cortex (Neural Capture)**. Aprèn el comportament d'amplificadors, pedals i caixes. Ofereix una versió que s'executa al mateix dispositiu i una altra al núvol, amb més resolució per a equips molt dinàmics com els *fuzz* i els compressors [49].
- **Neural Amp Modeler (NAM)**. Programari obert per entrenar i executar captures d'amplificadors i pedals, basat principalment en xarxes convolucionals [5].
- **GuitarML Proteus**. Connector obert (GPL-3.0) basat en una LSTM de 40 unitats executada amb RTNeural, que permet capturar també la posició d'un control [44].

La taula 2.2 en resumeix les diferències principals.

Taula 2.2: Comparació de solucions existents de captura neuronal.

| | **Quad Cortex** | **NAM** | **Proteus** |
|---|---|---|---|
| Tipus | Maquinari comercial | Programari obert | Connector obert (GPL-3.0) |
| Model | No publicat | Principalment convolucional | LSTM de 40 unitats |
| Entrenament | Al dispositiu o al núvol | Ordinador de l'usuari | Quadern en línia (Colab) |
| Controls | Captura fixa | Captura fixa | Fixa o un control |
| Execució | Dispositiu dedicat | Connector d'àudio | Connector amb RTNeural |

Els productes comercials no publiquen els detalls dels seus models. En canvi, NAM i Proteus són oberts i serveixen com a referència directa per a aquest treball. La mida de l'LSTM de Proteus, per exemple, és un indicador pràctic de la mida que es considera suficient per a ús real.

## 2.9 Síntesi i posicionament del treball

La revisió permet extreure les conclusions següents:

1. El modelatge neuronal de caixa negra és el mètode dominant per a la captura d'equips de distorsió i ha arribat a una qualitat que en proves d'escolta és difícil de distingir de l'original [4, 30, 35].
2. Per a la distorsió, les xarxes recurrents petites (LSTM, GRU) ofereixen un bon compromís entre precisió i cost [3, 31]. Tot i així, hi ha resultats contradictoris quan s'inclouen efectes amb més memòria, en què els models S4 i les TCN modulades són superiors [27, 21].
3. La funció de pèrdua influeix en la qualitat percebuda, i el pre-èmfasi és una pràctica ben establerta [36]. En canvi, la correspondència entre les mètriques objectives i la percepció continua sent un problema obert [36, 30].
4. L'aliàsing i la dependència de la freqüència de mostreig són limitacions identificades recentment, amb solucions encara en desenvolupament [43, 48].

A partir d'aquí s'identifiquen alguns **buits** en què aquest TFM pot aportar evidència:

- **Escenari d'usuari amb pocs recursos.** La majoria d'estudis treballen amb equips de laboratori, conjunts de dades curats o, en l'àmbit industrial, amb captures robotitzades. Hi ha poca evidència sistemàtica sobre quina quantitat i tipus de material gravat per un músic a casa és necessari, i quina mida mínima de model és suficient en aquest cas.
- **Comparació controlada per a la distorsió.** Les conclusions sobre quina arquitectura és millor difereixen entre estudis. Una comparació amb les mateixes dades, el mateix procediment d'entrenament i el mateix pressupost computacional, centrada en un efecte de distorsió concret, aporta evidència útil.

Aquest TFM se situa, doncs, en el modelatge de caixa negra amb xarxes neuronals (figura 2.1). Pren com a base metodològica els treballs de Wright *et al.* [3, 4, 36] i n'estén l'anàlisi en la direcció dels buits descrits. Aquestes conclusions justifiquen els objectius plantejats al capítol 1.

# Capítol 3

# Materials i mètodes

# Capítol 4

# Resultats

# Capítol 5

# Conclusions i treballs futurs

# Capítol 6

# Glossari

# Capítol 7

# Bibliografia

[1] Pakarinen J, Yeh DT. A review of digital techniques for modeling vacuum-tube guitar amplifiers. *Computer Music Journal*. 2009;33(2):85–100.

[2] Vanhatalo T, Legrand P, Desainte-Catherine M, Hanna P, Brusco A, Pille G, et al. A review of neural network-based emulation of guitar amplifiers. *Applied Sciences*. 2022;12(12):5894.

[3] Wright A, Damskägg EP, Välimäki V. Real-time black-box modelling with recurrent neural networks. A: *Proceedings of the 22nd International Conference on Digital Audio Effects (DAFx-19)*. Birmingham; 2019.

[4] Wright A, Damskägg EP, Juvela L, Välimäki V. Real-time guitar amplifier emulation with deep learning. *Applied Sciences*. 2020;10(3):766.

[5] Atkinson S. Neural Amp Modeler [programari]. GitHub; 2023 [consultat 26 oct. 2026]. Disponible a: `https://github.com/sdatkinson/neural-amp-modeler`

[6] Paszke A, Gross S, Massa F, Lerer A, Bradbury J, Chanan G, et al. PyTorch: an imperative style, high-performance deep learning library. A: *Advances in Neural Information Processing Systems 32 (NeurIPS)*. 2019. p. 8024–8035.

[7] Nacions Unides. Transformar el nostre món: l'Agenda 2030 per al Desenvolupament Sostenible. Resolució A/RES/70/1. Nova York: Assemblea General de les Nacions Unides; 2015.

[8] Strubell E, Ganesh A, McCallum A. Energy and policy considerations for deep learning in NLP. A: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*. Florència; 2019. p. 3645–3650.

[9] Reglament (UE) 2016/679 del Parlament Europeu i del Consell, de 27 d'abril de 2016, relatiu a la protecció de les persones físiques pel que fa al tractament de dades personals i a la lliure circulació d'aquestes dades (Reglament general de protecció de dades). *Diari Oficial de la Unió Europea*. 2016;L119:1–88.

[10] Oates BJ. *Researching Information Systems and Computing*. Londres: SAGE Publications; 2006.

[11] Yeh DT. Digital implementation of musical distortion circuits by analysis and simulation [tesi doctoral]. Stanford (CA): Stanford University; 2009.

[12] Yeh DT, Abel JS, Vladimirescu A, Smith JO. Automated physical modeling of nonlinear audio circuits for real-time audio effects—Part I: theoretical development. *IEEE Transactions on Audio, Speech, and Language Processing*. 2010;18(4):728–737.

[13] Werner KJ, Smith JO, Abel JS. Wave digital filter adaptors for arbitrary topologies and multiport linear elements. A: *Proceedings of the 18th International Conference on Digital Audio Effects (DAFx-15)*. Trondheim; 2015.

[14] Eichas F, Möller S, Zölzer U. Block-oriented gray box modeling of guitar amplifiers. A: *Proceedings of the 20th International Conference on Digital Audio Effects (DAFx-17)*. Edimburg; 2017.

[15] Novak A, Simon L, Kadlec F, Lotton P. Nonlinear system identification using exponential swept-sine signal. *IEEE Transactions on Instrumentation and Measurement*. 2010;59(8):2220–2229.

[16] Parker JD, Esqueda F, Bergner A. Modelling of nonlinear state-space systems using a deep neural network. A: *Proceedings of the 22nd International Conference on Digital Audio Effects (DAFx-19)*. Birmingham; 2019.

[17] Miklanek S, Wright A, Välimäki V, Schimmel J. Neural grey-box guitar amplifier modelling with limited data. A: *Proceedings of the 26th International Conference on Digital Audio Effects (DAFx23)*. Copenhaguen; 2023.

[18] Yeh YT, Chen YH, Cheng YC, Wu JT, Fu JJ, Yeh YF, et al. DDSP guitar amp: interpretable guitar amplifier modeling. arXiv:2408.11405 [preprint]. 2024.

[19] Damskägg EP, Juvela L, Thuillier E, Välimäki V. Deep learning for tube amplifier emulation. A: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. Brighton; 2019. p. 471–475.

[20] Steinmetz CJ, Reiss JD. Efficient neural networks for real-time modeling of analog dynamic range compression. A: *152nd Convention of the Audio Engineering Society*. 2022.

[21] Comunità M, Steinmetz CJ, Reiss JD. Differentiable black-box and gray-box modeling of nonlinear audio effects. *Frontiers in Signal Processing*. 2025;5:1580395. doi:10.3389/frsip.2025.1580395.

[22] Schmitz T, Embrechts JJ. Real time emulation of parametric guitar tube amplifier with long short term memory neural network. arXiv:1804.07145 [preprint]. 2018.

[23] van den Oord A, Dieleman S, Zen H, Simonyan K, Vinyals O, Graves A, et al. WaveNet: a generative model for raw audio. arXiv:1609.03499 [preprint]. 2016.

[24] Damskägg EP, Juvela L, Välimäki V. Real-time modeling of audio distortion circuits with deep learning. A: *Proceedings of the 16th Sound and Music Computing Conference (SMC-19)*. Màlaga; 2019.

[25] Martínez Ramírez MA, Reiss JD. Modeling nonlinear audio effects with end-to-end deep neural networks. A: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. Brighton; 2019. p. 171–175.

[26] Martínez Ramírez MA, Benetos E, Reiss JD. Deep learning for black-box modeling of audio effects. *Applied Sciences*. 2020;10(2):638.

[27] Comunità M, Steinmetz CJ, Phan H, Reiss JD. Modelling black-box audio effects with time-varying feature modulation. A: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. Rodes; 2023.

[28] Hochreiter S, Schmidhuber J. Long short-term memory. *Neural Computation*. 1997;9(8):1735–1780.

[29] Cho K, van Merriënboer B, Gulcehre C, Bahdanau D, Bougares F, Schwenk H, et al. Learning phrase representations using RNN encoder–decoder for statistical machine translation. A: *Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Doha; 2014. p. 1724–1734.

[30] Cassidy W, De Sena E. Perceptual evaluation and genre-specific training of deep neural network models of a high-gain guitar amplifier. A: *Proceedings of the 26th International Conference on Digital Audio Effects (DAFx23)*. Copenhaguen; 2023.

[31] Simionato R, Fasciani S. Comparative study of state-based neural networks for virtual analog audio effects modeling. *EURASIP Journal on Audio, Speech, and Music Processing*. 2025;2025. doi:10.1186/s13636-025-00416-3.

[32] Wilczek J, Wright A, Välimäki V, Habets EAP. Virtual analog modeling of distortion circuits using neural ordinary differential equations. A: *Proceedings of the 25th International Conference on Digital Audio Effects (DAFx20in22)*. Viena; 2022.

[33] Kuznetsov B, Parker JD, Esqueda F. Differentiable IIR filters for machine learning applications. A: *Proceedings of the 23rd International Conference on Digital Audio Effects (DAFx2020)*. Viena; 2020.

[34] Yeh YT, Hsiao WY, Yang YH. Hyper recurrent neural network: condition mechanisms for black-box audio effect modeling. A: *Proceedings of the 27th International Conference on Digital Audio Effects (DAFx24)*. Guildford; 2024.

[35] Juvela L, Damskägg EP, Peussa A, Mäkinen J, Sherson T, Mimilakis SI, et al. End-to-end amp modeling: from data to controllable guitar amplifier models. A: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. Rodes; 2023.

[36] Wright A, Välimäki V. Perceptual loss function for neural modelling of audio systems. A: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. Barcelona; 2020.

[37] Yamamoto R, Song E, Kim JM. Parallel WaveGAN: a fast waveform generation model based on generative adversarial networks with multi-resolution spectrogram. A: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. Barcelona; 2020. p. 6199–6203.

[38] Steinmetz CJ, Reiss JD. auraloss: audio focused loss functions in PyTorch. A: *Digital Music Research Network One-day Workshop (DMRN+15)*. Londres; 2020.

[39] Wright A, Välimäki V, Juvela L. Adversarial guitar amplifier modelling with unpaired data. A: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. Rodes; 2023.

[40] International Telecommunication Union. Recommendation ITU-R BS.1387-1: Method for objective measurements of perceived audio quality. Ginebra: ITU; 2001.

[41] Kilgour K, Zuluaga M, Roblek D, Sharifi M. Fréchet Audio Distance: a reference-free metric for evaluating music enhancement algorithms. A: *Proceedings of Interspeech 2019*. Graz; 2019.

[42] International Telecommunication Union. Recommendation ITU-R BS.1534-3: Method for the subjective assessment of intermediate quality level of audio systems. Ginebra: ITU; 2015.

[43] Carson A, Wright A, Chowdhury J, Välimäki V, Bilbao S. Sample rate independent recurrent neural networks for audio effects processing. A: *Proceedings of the 27th International Conference on Digital Audio Effects (DAFx24)*. Guildford; 2024.

[44] Bloemer K. Proteus [programari]. GuitarML; GitHub [consultat 26 oct. 2026]. Disponible a: `https://github.com/GuitarML/Proteus`

[45] Pedroza HE, Meza G, Roman IR. EGFxSet: electric guitar tones processed through real effects of distortion, modulation, delay and reverb. A: *Late-Breaking Demo Session, 23rd International Society for Music Information Retrieval Conference (ISMIR)*. Bengaluru; 2022.

[46] Wright A, Carson A, Juvela L. Open-Amp: synthetic data framework for audio effect foundation models. A: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. Hyderabad; 2025. p. 1–5.

[47] Chowdhury J. RTNeural: fast neural inferencing for real-time systems. arXiv:2106.03037 [preprint]. 2021.

[48] Carson A, Välimäki V, Wright A, Bilbao S. Resampling filter design for multirate neural audio effect processing. arXiv:2501.18470 [preprint]. 2025.

[49] Neural DSP Technologies. Quad Cortex [Internet]. [consultat 26 oct. 2026]. Disponible a: `https://neuraldsp.com/us/quad-cortex`

# Capítol 8

# Annexos